

RELATÓRIO

Experimentação com redes neurais convolucionais



Pedro Antônio de Souza Silva

INTRODUÇÃO

A proposta deste projeto foi avaliar o desempenho de redes neurais convolucionais para reconhecimento de gestos com a base de dados “*Massey _ Parte 1*”. Para isto, foram utilizados diferentes parâmetros e redes, que serão listados abaixo.

Parâmetros Testados

1. **Taxas de Aprendizado:**
 - a. 0.5
 - b. 0.1
 - c. *0.01
2. **Épocas de Treinamento:**
 - a. 10
 - b. 15
 - c. *20
3. **Otimizadores:**
 - a. Gradiente Descendente
 - b. Gradiente Adaptativo (Adagrad)
 - c. Adam

Redes Testadas

1. LeNet (adaptada para entrada RGB)
2. MiniVgg
3. *LeNet Modificada (modificações nas camadas intermediárias e quantidade de filtros)

Esclarecimentos sobre Limitações

1. Com o limite atingido para CPU, GPU e TPU no *Colab* (*o mesmo começou a cortar as execuções assim que eram inicializadas dizendo que não há backends disponíveis, para os 3 tipos de dispositivos*), alguns dados tiveram que ser calculados com menos execuções (padrão normal de 30 execuções).

Com os cortes das contas, não foi possível calcular nenhuma das redes com 20 épocas de

treinamento, nem a rede **LeNet Modificada**.

Tabelas de Resultados

- GD = Gradiente Descendente
- AGD = Adaptavel GD (Adagrad)
- A = Adam
 - LenetMod foi cortada, pois não pode ser calculada (apesar de funcionar, eu testei o código e vou mandar em anexo)

Digite seu texto aqui	Learning Rate	Otimizador	Precisão Média 10 Épocas	Desvio Padrão da Precisão 10 Épocas	Precisão Média 15 Épocas	Desvio Padrão da Precisão 15 Épocas
Lenet (RGB)	0.5	GD	1.61%	0.72	1.53%	0.51
MiniVGG	0.5	GD	81.29%	4.41	86.98	5,47

Digite seu texto aqui	Learning Rate	Otimizador	Precisão Média 10 Épocas	Desvio Padrão da Precisão 10 Épocas	Precisão Média 15 Épocas	Desvio Padrão da Precisão 15 Épocas
Lenet (RGB)	0.1	GD	83.51%	7.03	89.72%	5.66
MiniVGG	0.1	GD	92.81%	2.58	95.09%	1.47

Digite seu texto aqui	Learning Rate	Otimizador	Precisão Média 10 Épocas	Desvio Padrão da Precisão 10 Épocas	Precisão Média 15 Épocas	Desvio Padrão da Precisão 15 Épocas
Lenet (RGB)	0.01	GD	2.44%	0.77	73.38%	18.77
MiniVGG	0.01	GD	98.81	0.68	98.68	0.84

Digite seu texto aqui	Learning Rate	Otimizador	Precisão Média 10 Épocas	Desvio Padrão da Precisão 10 Épocas	Precisão Média 15 Épocas	Desvio Padrão da Precisão 15 Épocas
Lenet (RGB)	0.5	AGD	4.66%	6.14	8.27%	11.21
MiniVGG	0.5	AGD	86.62%	4.48	91.85%	2.25

Digite seu texto aqui	Learning Rate	Otimizador	Precisão Média 10 Épocas	Desvio Padrão da Precisão 10 Épocas	Precisão Média 15 Épocas	Desvio Padrão da Precisão 15 Épocas
Lenet (RGB)	0.1	AGD	35.90%	42.19	57.27%	45.00*
MiniVGG	0.1	AGD	92.40%	3.04	97.59%	1.29

Digite seu texto aqui	Learning Rate	Otimizador	Precisão Média 10 Épocas	Desvio Padrão da Precisão 10 Épocas	Precisão Média 15 Épocas	Desvio Padrão da Precisão 15 Épocas
Lenet (RGB)	0.01	AGD	63.72	4.90	96.01%	1.58
MiniVGG	0.01	AGD	96.31%	1.02	95.79%	1.85

Digite seu texto aqui	Learning Rate	Otimizador	Precisão Média 10 Épocas	Desvio Padrão da Precisão 10 Épocas	Precisão Média 15 Épocas	Desvio Padrão da Precisão 15 Épocas
Lenet (RGB)	0.5	A	2.61%	0.90	2.2%	0.72
MiniVGG	0.5	A	4.55%	1.46	3.5%	1.57

Digite seu texto aqui	Learning Rate	Otimizador	Precisão Média 10 Épocas	Desvio Padrão da Precisão 10 Épocas	Precisão Média 15 Épocas	Desvio Padrão da Precisão 15 Épocas
Lenet (RGB)	0.1	A	1.9%	0.86	2.01%	0.83
MiniVGG	0.1	A	37.81%	4.99	45.46%	7.08

Digite seu texto aqui	Learning Rate	Otimizador	Precisão Média 10 Épocas	Desvio Padrão da Precisão 10 Épocas	Precisão Média 15 Épocas	Desvio Padrão da Precisão 15 Épocas
Lenet (RGB)	0.01	A	95.48%	1.75	29.68%	38.43
MiniVGG	0.01	A	89.18%	3.10	-----*	-----*

(Como todas as contas foram bloqueadas no Colab, não foi possível calcular as médias para MiniVgg com Adam para treinamentos de 15 épocas)

Conclusões

1. Sobre as **Redes**:
 - a. A rede **MiniVgg** teve desempenho muito superior à **LeNet(RGB)** em todos os casos de testes, exceto com o otimizador **Adam** com **lr inicial = 0.01**
2. Sobre os **Otimizadores**:
 - a. Dos otimizadores testados, o **AGD (gradiente descendente adaptativo)** foi o que obteve melhores resultados para as redes (*com exceção do caso de lr inicial = 0.1*)
 - b. O tipo de otimizador pode influenciar **pesadamente** no aprendizado, a depender da quantidade de épocas e da taxa de aprendizagem.
3. Sobre as **Taxas de Aprendizado**:
 - a. As taxas de aprendizado precisam ter um equilíbrio em harmonia com seu otimizador, como visto, o **GD (gradiente descendente)** obteve resultados muito ruins com $lr = 0.5$ e $lr = 0.001$, mas ótimos resultados com $lr = 0.1$. Já outros os otimizadores, obtiveram melhores resultados com outras taxas de aprendizado iniciais.
 - b. A taxa de aprendizado deve ser utilizada com cuidado em harmonia com seu otimizador.
4. Sobre as **Épocas de Treinamento**:
 - a. Na maioria dos casos, mais épocas de treinamento significaram melhores resultados, mas no caso do otimizador **Adam**, o desempenho foi perdido pela **LeNet(RGB)** a partir das 15 épocas de treinamento.
 - b. A depender do otimizador, a quantidade de épocas ideal pode variar, treinar demais pode custar todo o progresso feito pela rede.